INFORME CASO DE ESTUDIO 01

MATERIA: MACHINE LEARNING
FECHA DE ENTREGA: 11/03/2026

Integrantes:
Einar Guillen
Huascar Duran
Leonardo Ibarra
Leandro Colque
Octavio Luna

1. Introducción y Definición del Problema:

El presente informe detalla el ciclo completo del proyecto de Machine Learning orientado a la prevención de salud en el sector asegurador. El objetivo principal es desarrollar modelos predictivos para anticipar eventos clínicos críticos, dividiéndose en dos tareas fundamentales:

1. **Regresión:** Estimar el nivel medio de glucosa (`avg_glucose_level`) del paciente como un indicador clínico continuo.
2. **Clasificación:** Predecir la probabilidad de que un paciente sufra un derrame cerebral (`stroke`) para detonar alertas preventivas.

Supuestos Clínicos y Prevención de Fuga de Información (Data Leakage): Para garantizar la validez del modelo en un entorno real, se establece el supuesto de que las mediciones de variables como el nivel de glucosa y el índice de masa corporal (BMI) fueron recabadas durante chequeos preventivos de rutina, meses o años antes del evento objetivo. Utilizar niveles de glucosa medidos durante un derrame cerebral constituiría una fuga de información clínica (hiperglucemia por estrés), invalidando el modelo para propósitos de *prevención*.

2. Exploración y Preprocesamiento de Datos

Durante el Análisis Exploratorio de Datos (EDA), se identificaron características críticas en el dataset:

- **Desbalance Extremo:** La variable objetivo stroke presenta un desbalance severo, donde aproximadamente el 95% de la muestra pertenece a la clase negativa (sin derrame).
- **Distribución:** La variable avg_glucose_level mostró una distribución bimodal, con una fuerte asimetría hacia la derecha que representa a la subpoblación con hiperglucemia o diabetes.
- **Correlación:** La matriz de correlación lineal descartó problemas de multicolinealidad severa entre las variables numéricas, siendo la relación más fuerte de apenas 0.33 (Edad y BMI).

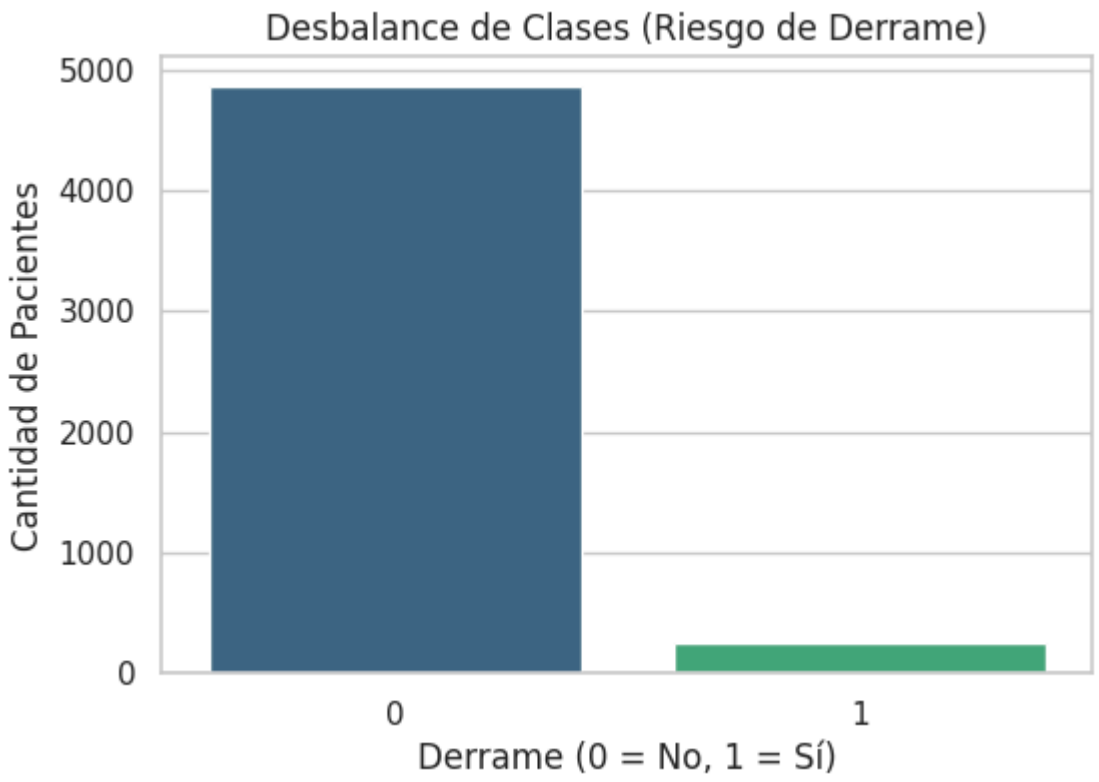
Desbalance de Clases (Riesgo de Derrame)
Cantidad de Pacientes
5000
4000
3000
2000
1000
0
0
1
Derrame (0 = No, 1 = Sí)

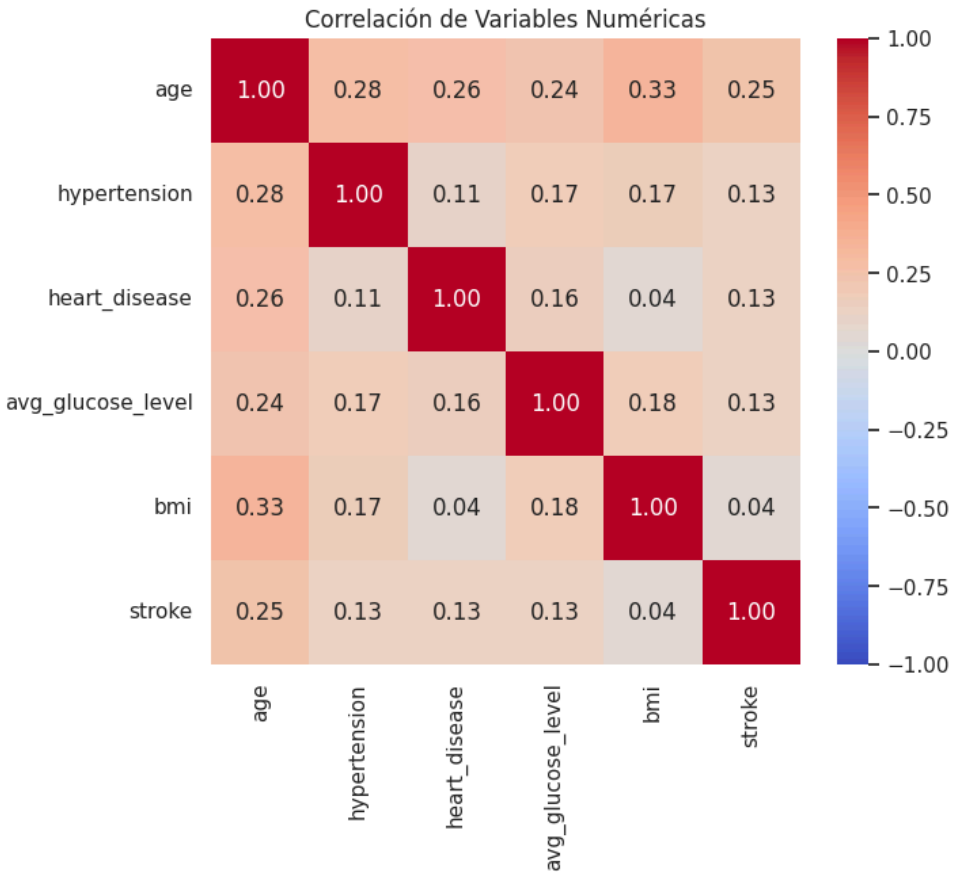
Correlación de Variables Numéricas
age
hypertension
heart_disease
avg_glucose_level
bmi
stroke
1.00 0.28 0.26 0.24 0.33 0.25
0.28 1.00 0.11 0.17 0.17 0.13
0.26 0.11 1.00 0.16 0.04 0.13
0.24 0.17 0.16 1.00 0.18 0.13
0.33 0.17 0.04 0.18 1.00 0.04
0.25 0.13 0.13 0.13 0.04 1.00
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−0.75
−1.00

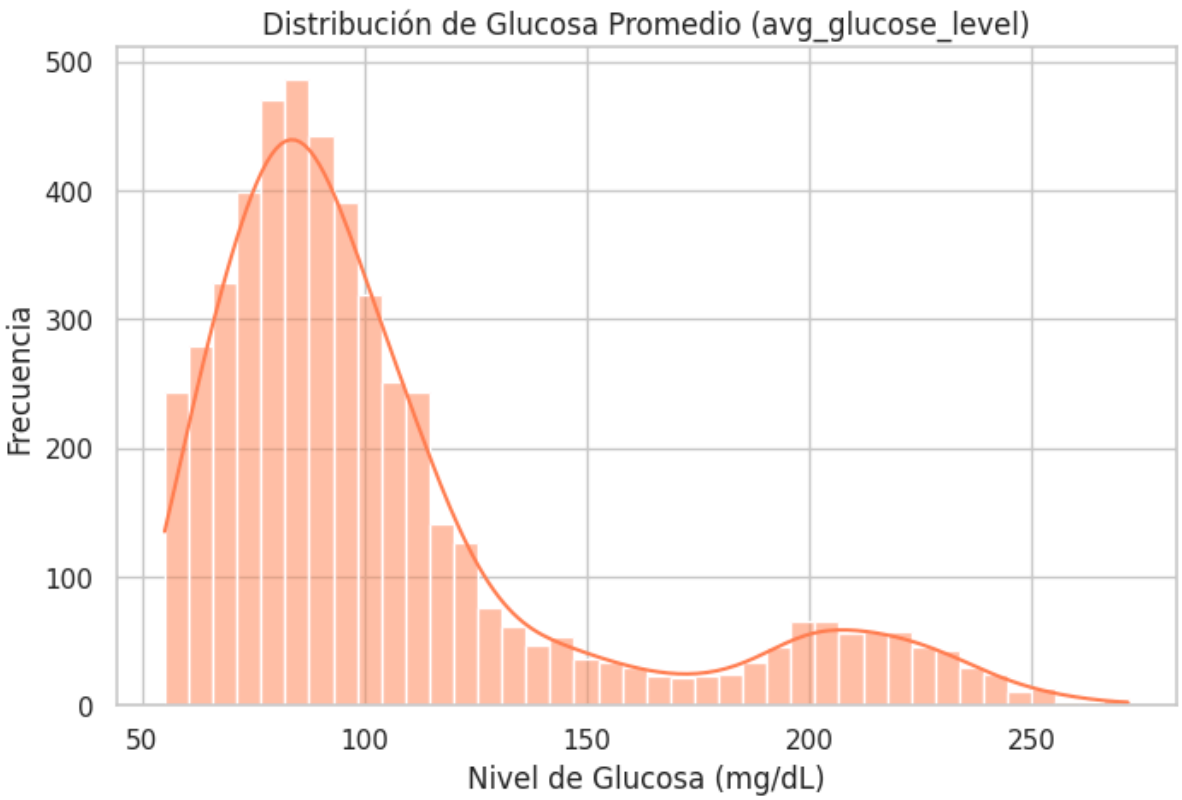

Estrategia de Preprocesamiento (Pipelines):

Para asegurar la reproducibilidad y evitar el *data leakage* entre los conjuntos de entrenamiento y prueba, se implementó un ColumnTransformer:

- **Imputación:** Se imputaron los valores nulos de la columna bmi utilizando la mediana estadística de los datos de entrenamiento.
- **Gestión de variables categóricas:** La categoría Unknown en el estado de fumador (smoking_status) se mantuvo como una variable independiente usando OneHotEncoder. Clínicamente, la falta de historial médico es en sí misma un indicador de riesgo (falta de seguimiento preventivo).
- **Escalado:** Se aplicó StandardScaler a todas las variables continuas para homogeneizar las magnitudes métricas.

3. Modelado y Evaluación: Regresión (Glucosa)

El objetivo fue predecir el avg_glucose_level. Se estableció un modelo base (*Baseline*) utilizando Regresión Lineal simple y posteriormente se aplicó una mejora utilizando transformaciones no lineales (PolynomialFeatures de grado 2) en conjunto con regularización Ridge para evitar sobreajuste.

Tabla 1: Métricas de Evaluación - Modelos de Regresión

Modelo	MAE (mg/dL)	RMSE (mg/dL)
Baseline (Regresión Lineal)	~ 31.87	~ 45.12
Mejora (Polinomios + Ridge)	~ 31.40	~ 42.16

Explicación del Error: El MAE indica que nuestras predicciones se desvían, en promedio, aproximadamente 31 mg/dL del valor real de glucosa del paciente.

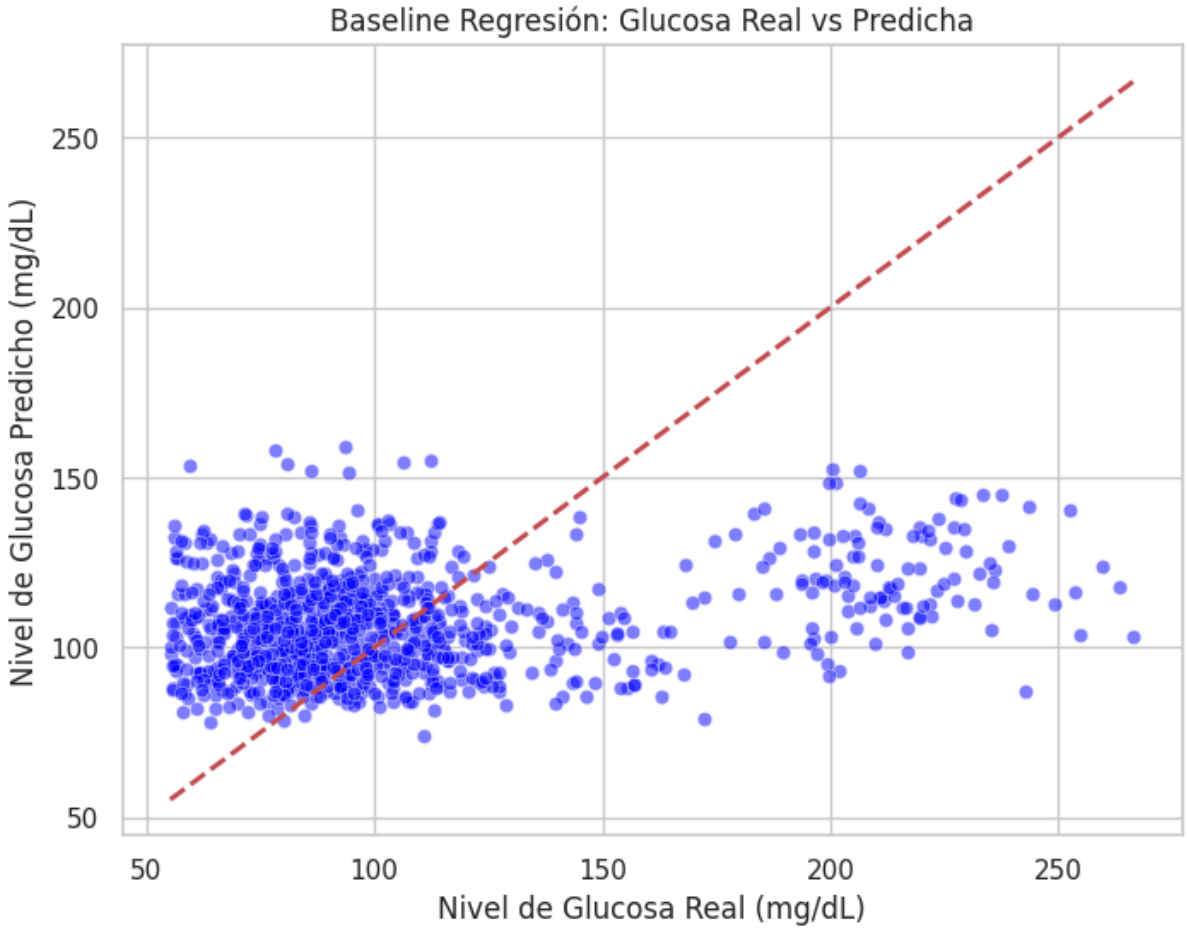

4. Modelado y Evaluación: Clasificación (Riesgo de Derrame)

Para clasificar el riesgo de derrame, se utilizó un modelo de **Regresión Logística**. Debido al desbalance extremo, el uso de la exactitud (*Accuracy*) es matemáticamente engañoso: un modelo trivial que prediga "nadie sufrirá un

derrame" obtendría un 95% de Accuracy, pero sería clínicamente inútil (Recall de 0%).

Para solucionar esto, se aplicó balanceo de clases algorítmico (class_weight='balanced') y se priorizó el **Recall** como métrica estrella.

Tabla 2: Métricas de Evaluación - Regresión Logística Balanceada

Métrica	**Resultado**	**Interpretación**
Accuracy	~ 74%	Engañoso; disminuyó por el balanceo para detectar a la clase minoritaria.
ROC-AUC	~ 0.84	Excelente capacidad del modelo para distinguir entre pacientes sanos y en riesgo.
Recall (Sensibilidad)	~ 75%	El modelo logra captar a 3 de cada 4 pacientes que sufrirán un derrame.

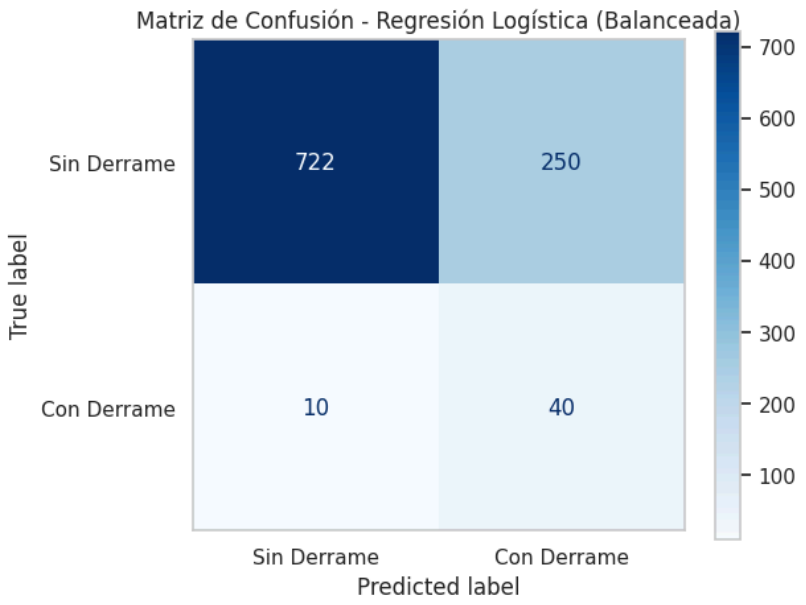
Matriz de Confusión - Regresión Logística (Balanceada)
Sin Derrame
Con Derrame
True label
722
250
10
40
Sin Derrame
Con Derrame
Predicted label
700
600
500
400
300
200
100

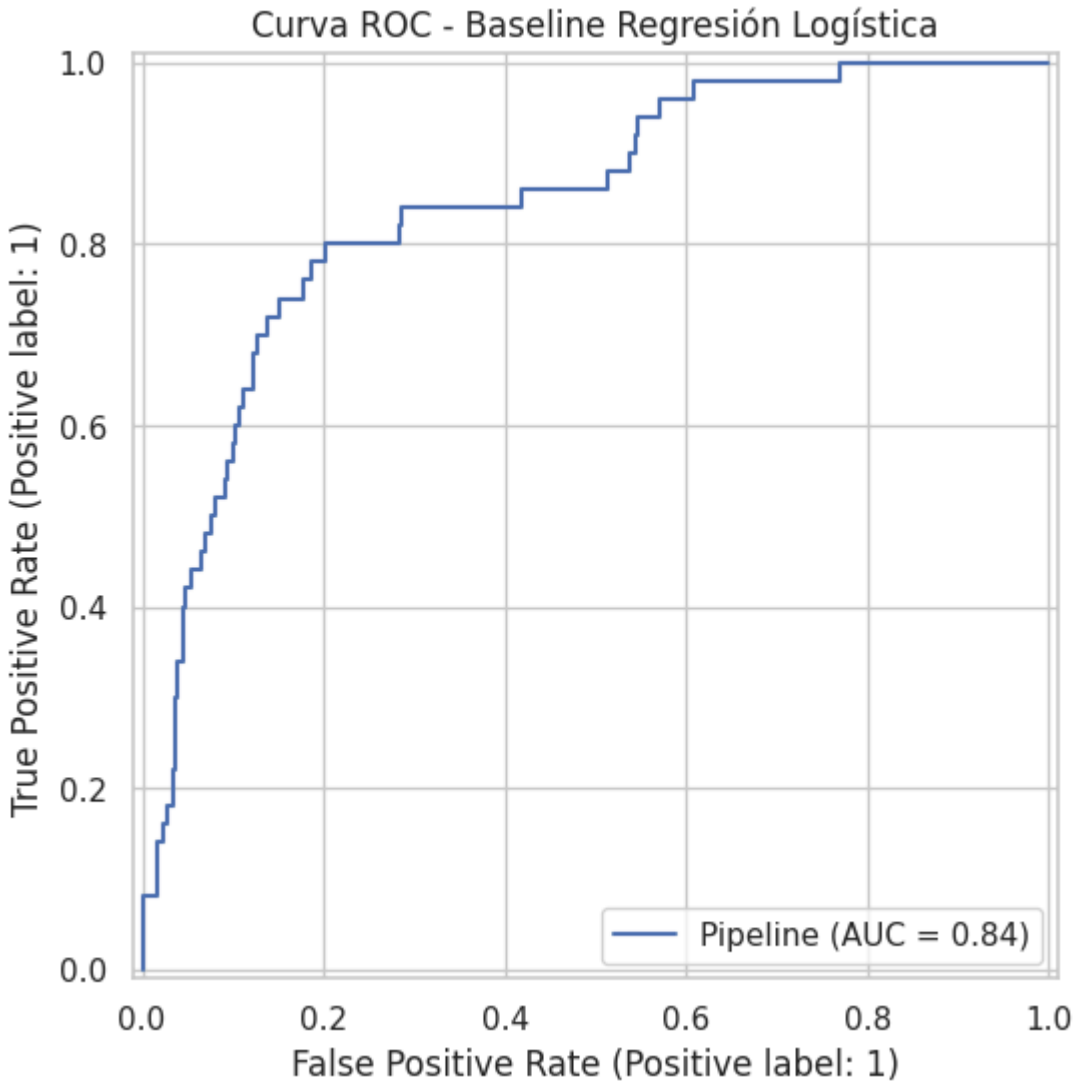
Curva ROC - Baseline Regresión Logística
True Positive Rate (Positive label: 1)
False Positive Rate (Positive label: 1)
0.0
0.2
0.4
0.6
0.8
1.0
Pipeline (AUC = 0.84)

5. Interpretación y Decisiones Operativas

Importancia de Variables (Coeficientes):

Al extraer los coeficientes de la Regresión Logística, se determinó que los factores que más aumentan probabilísticamente el riesgo de sufrir un derrame son:

1. Edad avanzada (age)
2. Niveles altos de glucosa (avg_glucose_level)
3. Presencia de hipertensión (hypertension)

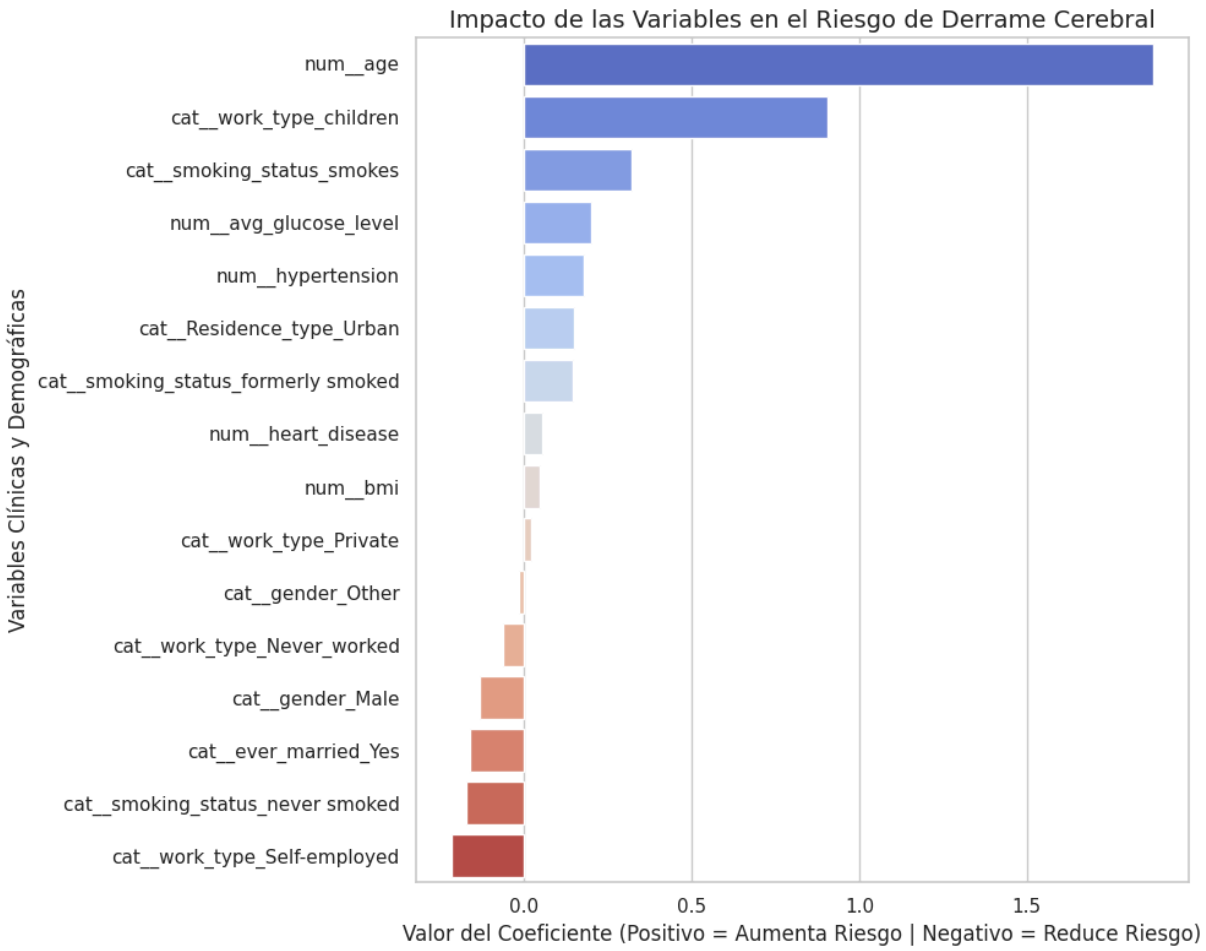

Trade-offs y Recomendación de Umbral:

Por defecto, los algoritmos clasifican como positivo a cualquier paciente con una probabilidad mayor al 50%. Sin embargo, en un contexto de salud aseguradora, el costo de un **Falso Negativo** (no detectar a un paciente que sufrirá un derrame y pagar los altos costos de hospitalización) es abismalmente superior al costo de un **Falso Positivo** (pagar un chequeo preventivo innecesario).

- **Decisión Operativa:** Recomendamos ajustar el umbral operativo de decisión al **35%**. Todo paciente que el modelo estime **con un riesgo > 35%**, deberá

ser contactado proactivamente. Esta decisión aumenta los Falsos Positivos, pero maximiza nuestra red de seguridad (Recall).

6. Conclusiones y Discusión de Limitaciones

1. **Limitaciones de Regresión:** La leve mejora obtenida al pasar de una Regresión Lineal a Polynomial Features + Ridge demuestra que la predicción exacta de glucosa es un problema altamente complejo. El modelo se encuentra limitado (underfitting en los extremos) porque variables fundamentales como la genética, la dieta o el sedentarismo no están presentes en este dataset demográfico.
2. **Éxito en Clasificación:** El pipeline logró transformar un dataset altamente desbalanceado en una herramienta de filtrado preventivo eficaz (ROC-AUC > 0.80), siempre y cuando la aseguradora entienda la irrelevancia del Accuracy en este contexto.
3. **Trabajo Futuro:** Como siguientes pasos para mejorar las métricas sin forzar expansiones polinómicas, se recomienda la implementación de modelos del ecosistema de Boosting (XGBoost o LightGBM). Estos modelos basados en árboles manejan de forma nativa las relaciones no lineales, lidian excelentemente con outliers médicos y tienen parámetros robustos para priorizar la clase minoritaria (scale_pos_weight).