STROKE PREVENTION ANALYTICS

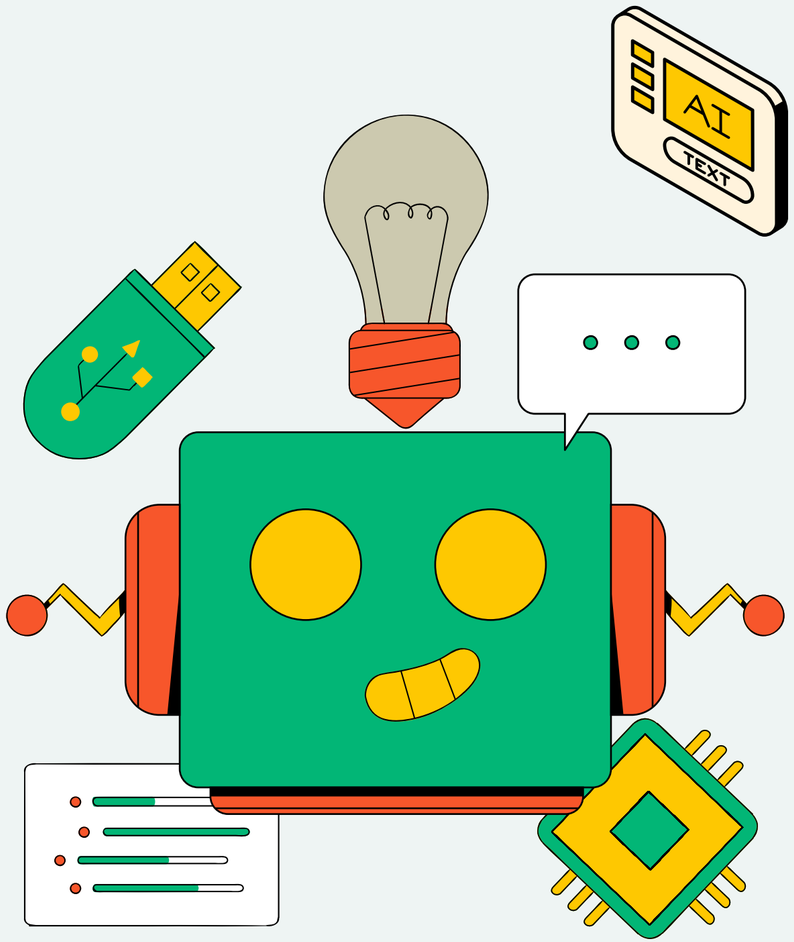

PREDICCIÓN Y PREVENCIÓN DE DERRAMES CEREBRALES CON MACHINE LEARNING.

PRESENTADO POR:

EQUIPO: EINAR GUILLEN, HUASCAR DURAN, LEONARDO IBARRA, LEANDRO COLQUE, OCTAVIO LUNA.

CONTEXTO Y OBJETIVO DEL NEGOCIO

El Problema: El derrame cerebral es una emergencia médica que necesitamos anticiparnos.

Objetivos:

- Regresión: Estimar el nivel medio de glucosa.
- Clasificación: Predecir la probabilidad de sufrir un derrame.

Supuesto Clínico (Prevención de Leakage): Los datos (Glucosa, BMI) asumen una medición en chequeos preventivos previos, no durante la emergencia, para evitar la fuga de información por hiperglucemia de estrés.

ANÁLISIS EXPLORATORIO (EDA)

- **Desbalance extremo: 95% de pacientes sanos vs. 5% con historial de derrame.**
- **Distribución de glucosa asimétrica (presencia de picos de diabetes).**
- **Cada variable aporta información única y no redundante (Correlación baja, máximo 0.33).**

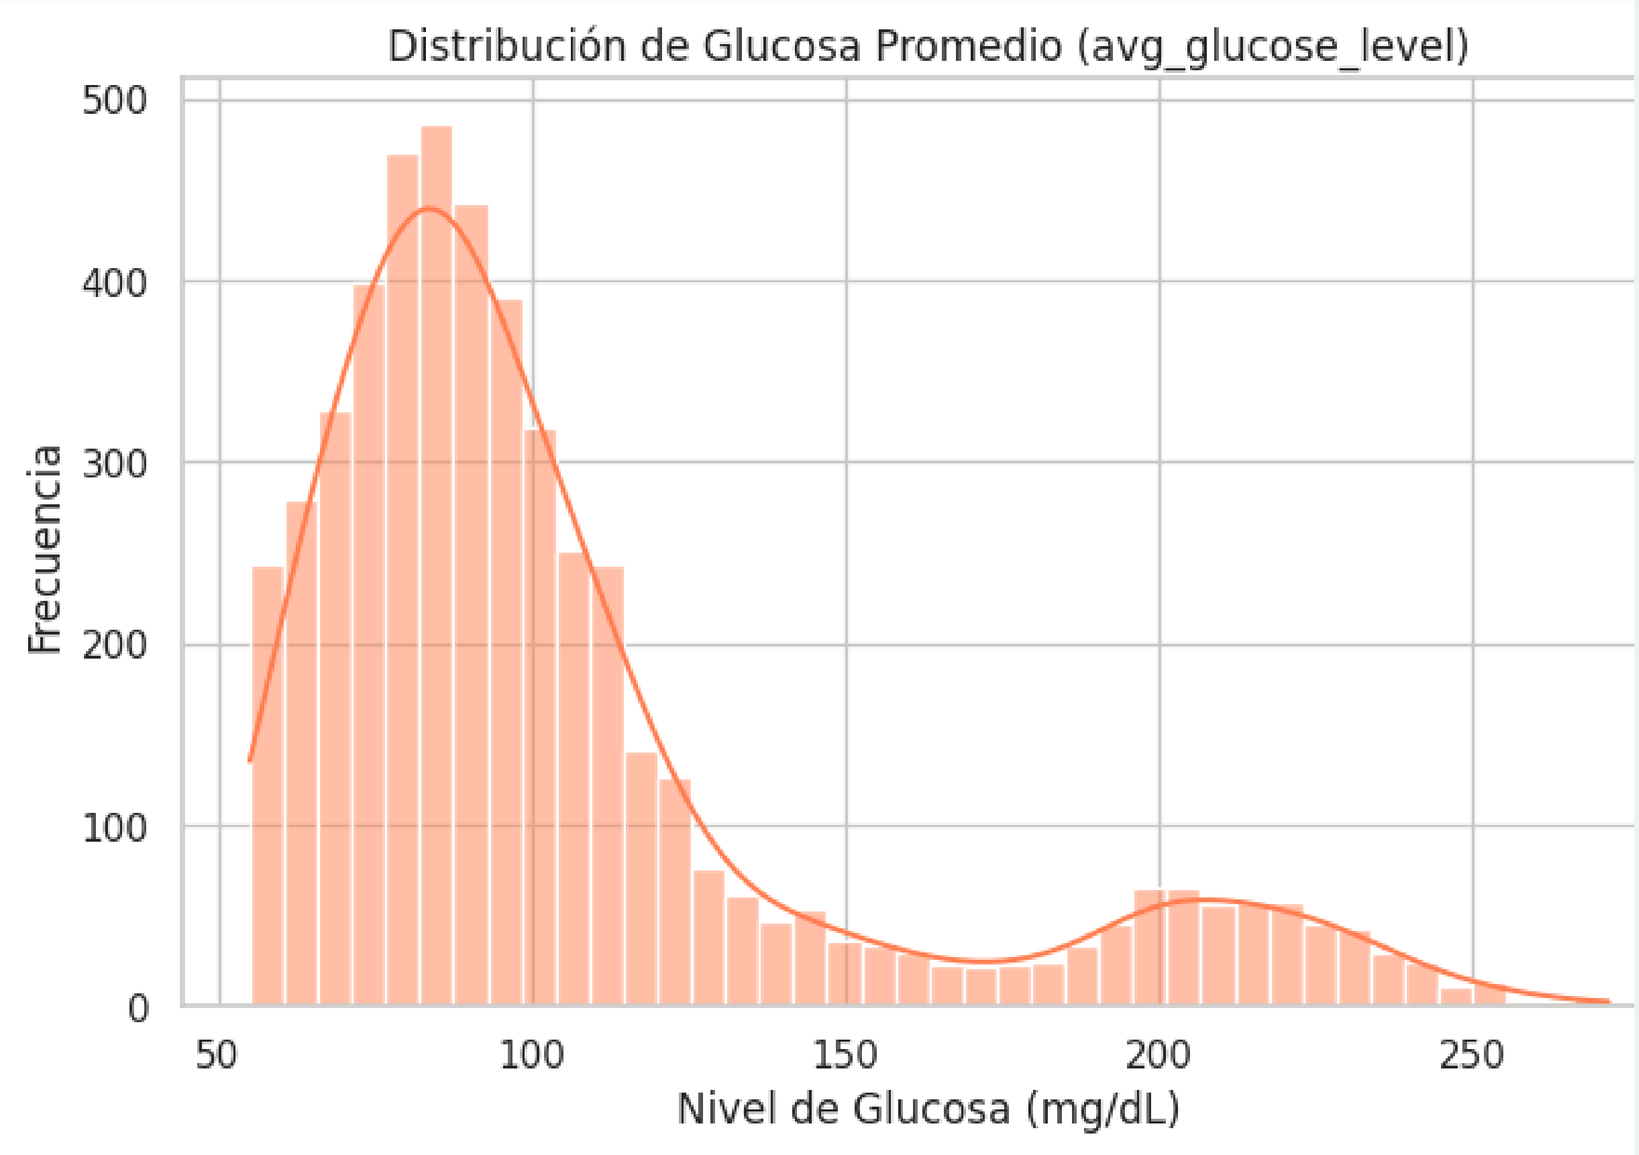

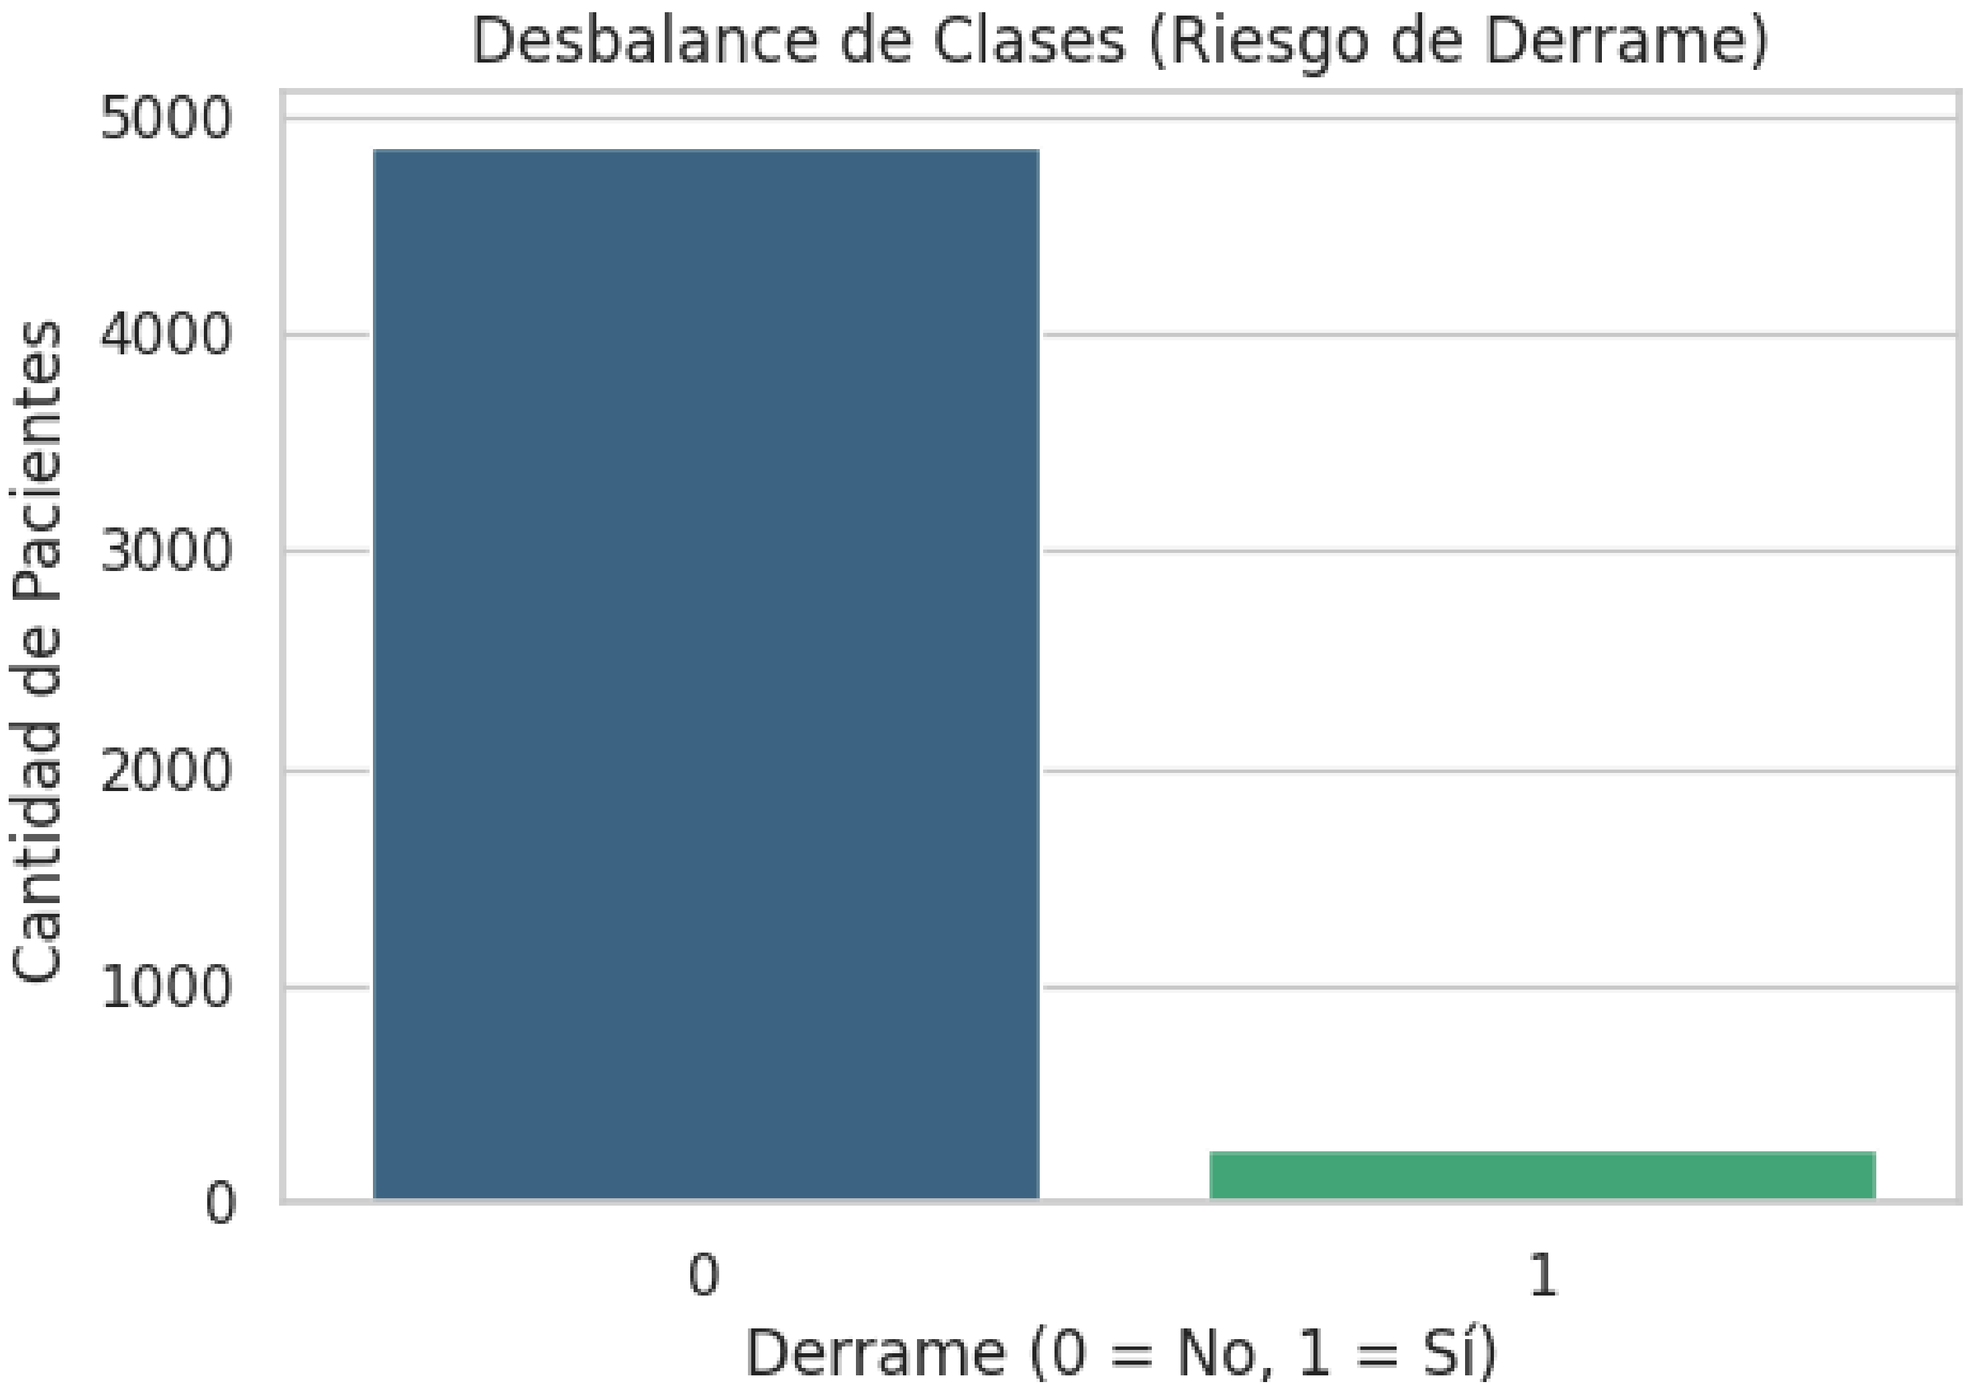
Desbalance de Clases (Riesgo de Derrame)
Cantidad de Pacientes
5000
4000
3000
2000
1000
0
0
1
Derrame (0 = No, 1 = Sí)

METODOLOGÍA Y PREPROCESAMIENTO

- Uso estricto de Pipelines (ColumnTransformer) para evitar fuga de datos.
- Imputación de nulos en bmi con la mediana.
- La categoría Unknown en fumadores se conservó como factor de riesgo (falta de historial).
- Variables escaladas (StandardScaler) y codificadas (OneHotEncoder).

RESULTADOS DE REGRESIÓN (GLUCOSA)

Baseline: Regresión Lineal Simple (MAE: ~31.87 mg/dL).

Mejora: PolynomialFeatures (Grado 2) + Ridge (MAE: ~31.65 mg/dL).

Interpretación: Predecir picos exactos de glucosa solo con datos demográficos es complejo.

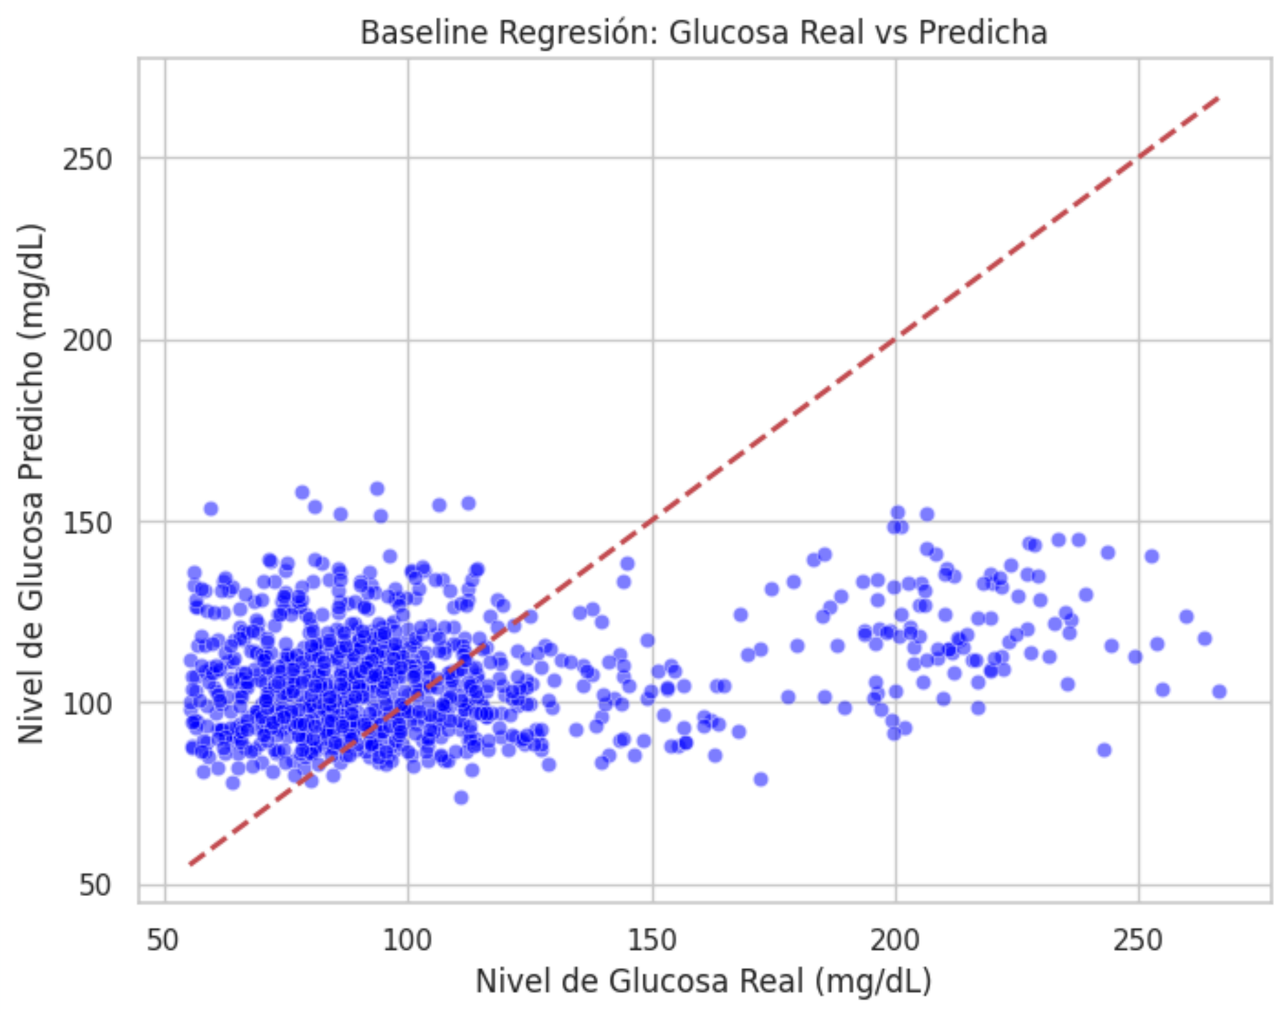

CLASIFICACIÓN - EL PELIGRO DEL "ACCURACY"

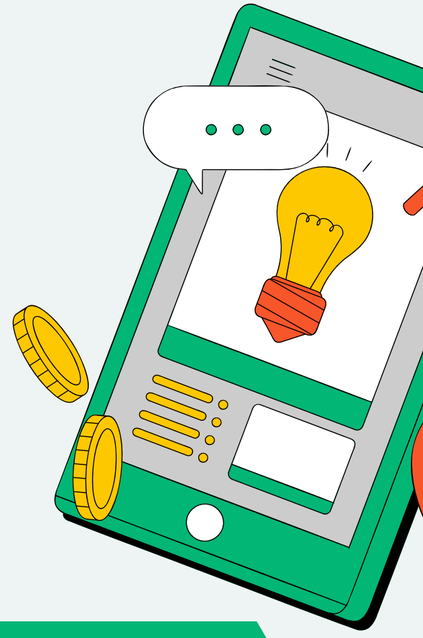

El problema: Un modelo inútil que diga "nadie tendrá derrames" tendría un 95% de Accuracy.

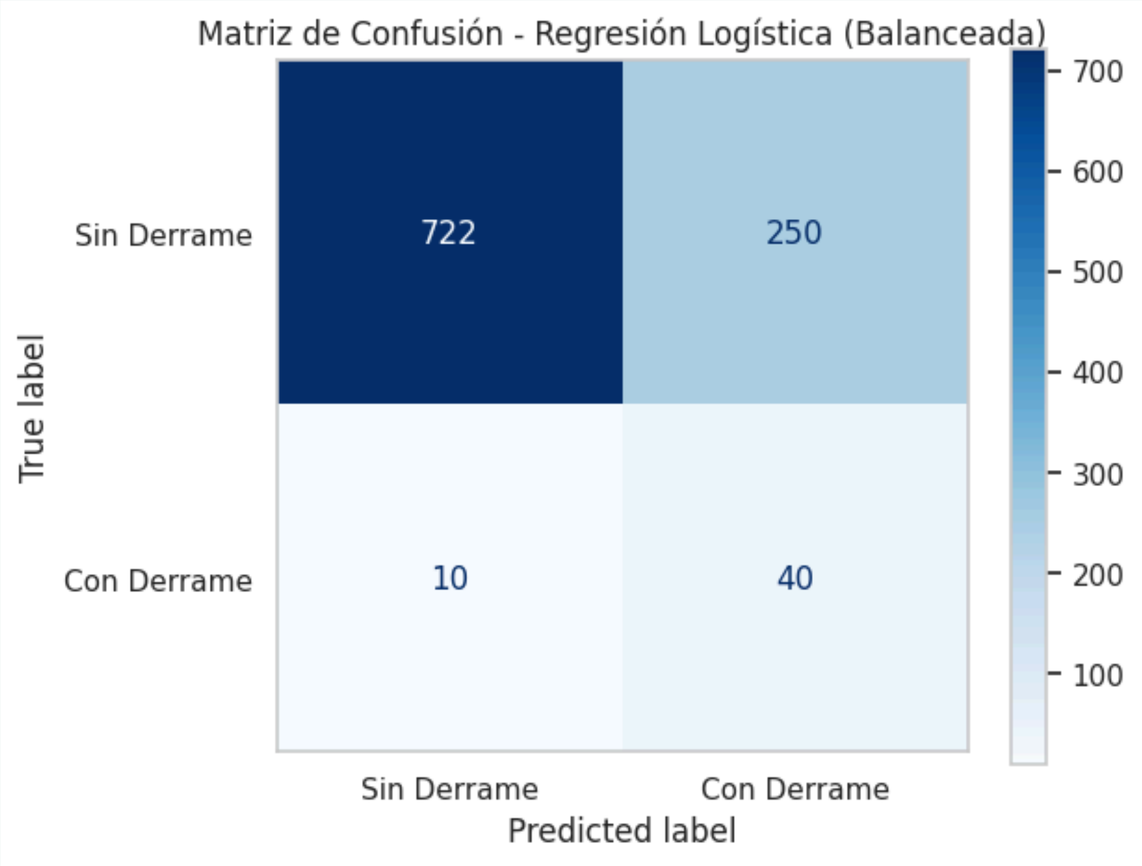

La Solución: Balancear los pesos de las clases y priorizar la métrica de Recall (Sensibilidad).

EVALUACIÓN DE CLASIFICACIÓN

- ROC-AUC (~0.84): Excelente separación entre pacientes sanos y en riesgo.
- Recall (~75%): Detectamos a la gran mayoría de pacientes en peligro.

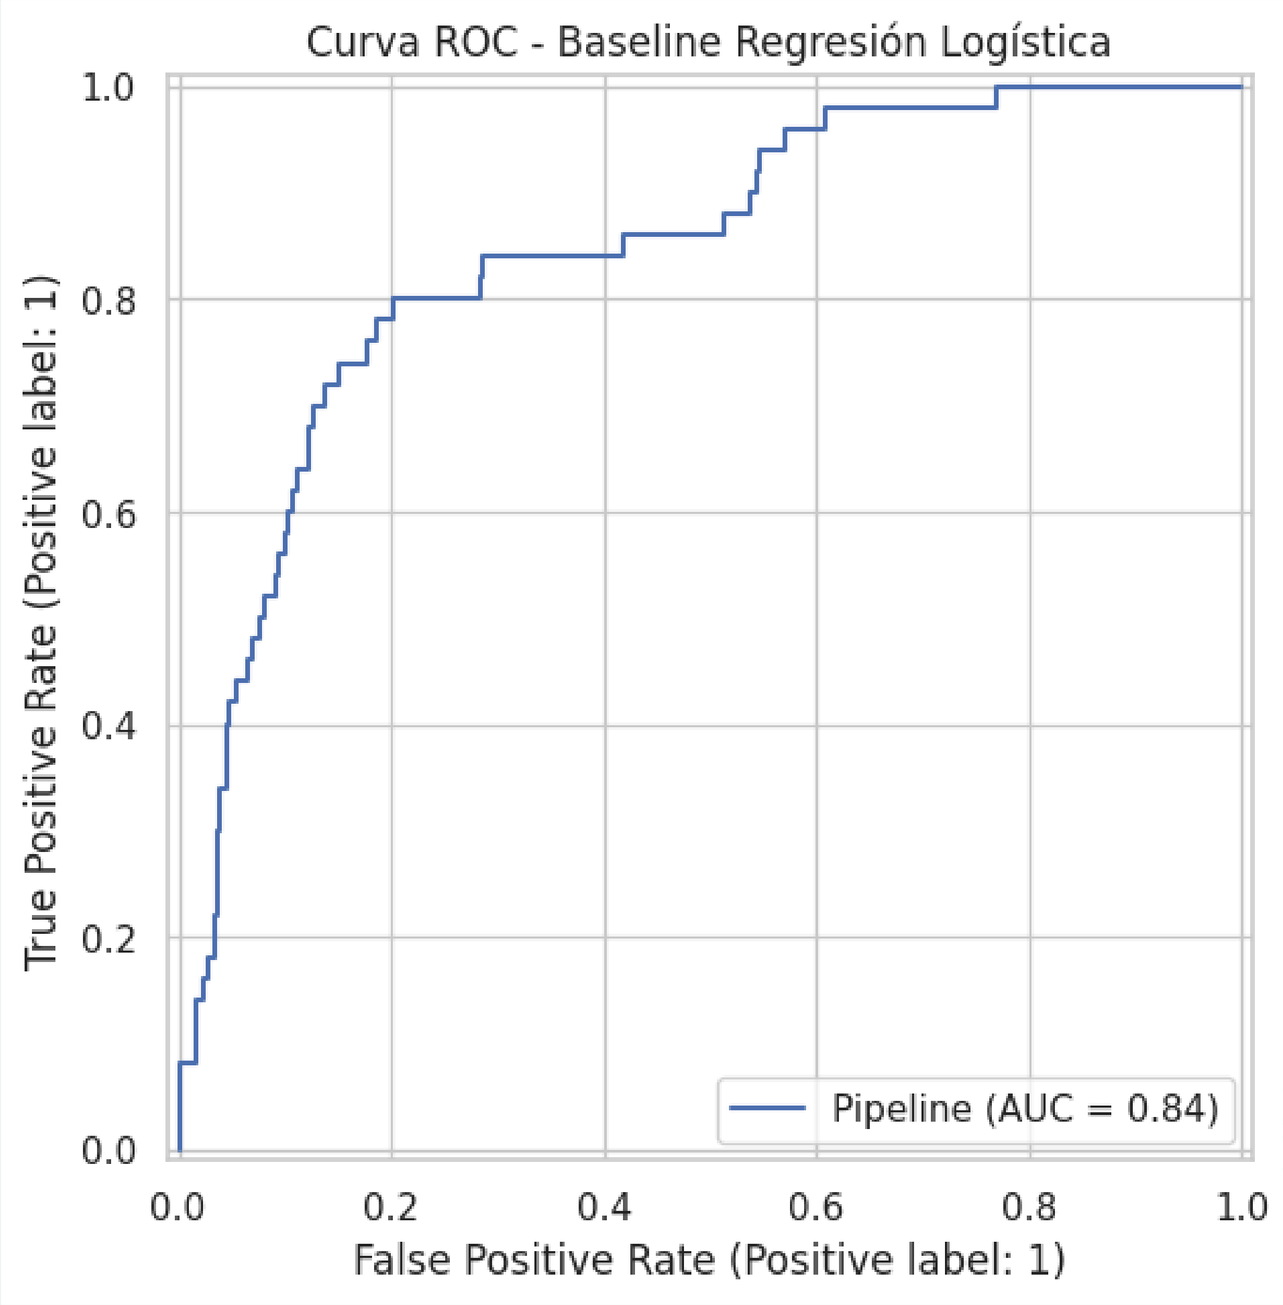

DIAGNÓSTICO DEL MODELO

Evaluación de la estabilidad del modelo con validación cruzada.

Las curvas muestran si el modelo necesita más datos o si ya estabilizó su aprendiza

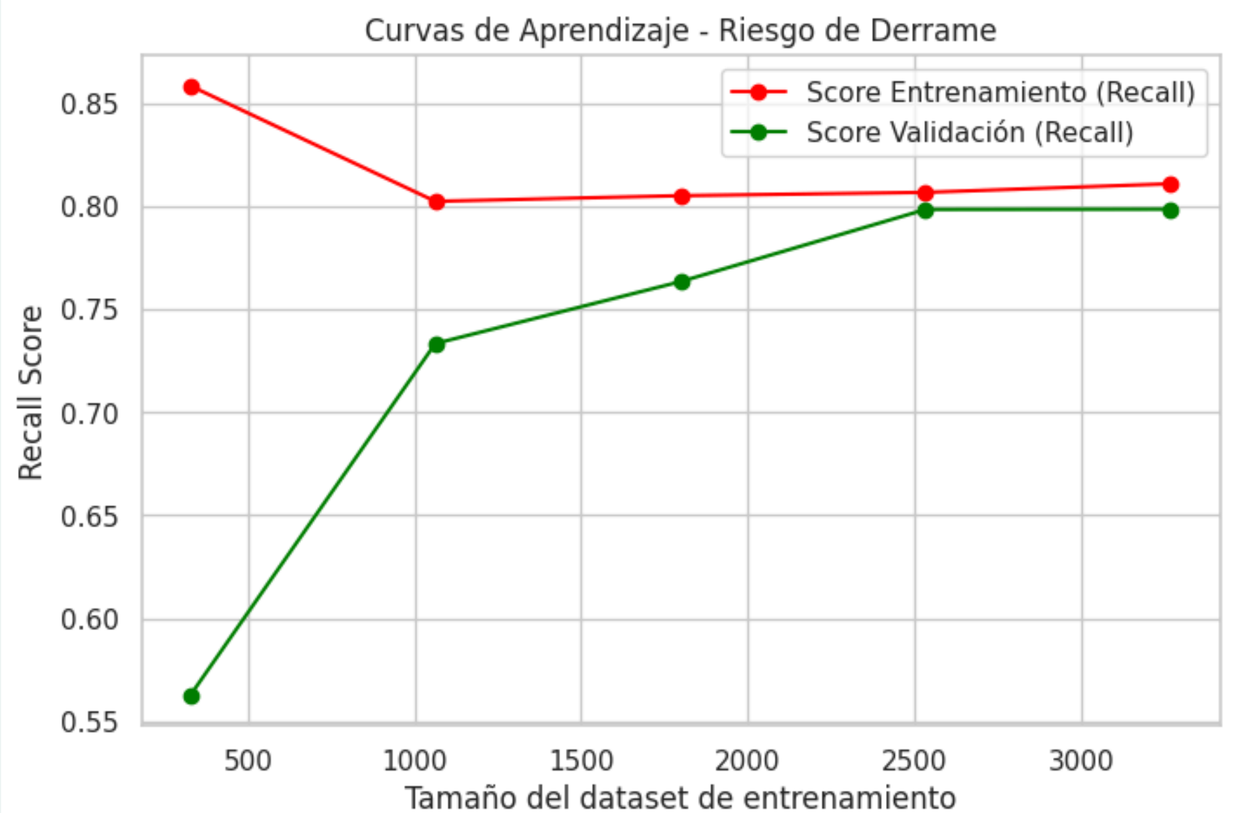

INTERPRETACIÓN CLÍNICA (EXPLICABILIDAD)

- ¿Qué factores disparan nuestras alarmas?
- El modelo es transparente: Edad avanzada, niveles altos de glucosa e hipertensión son los detonantes principales.

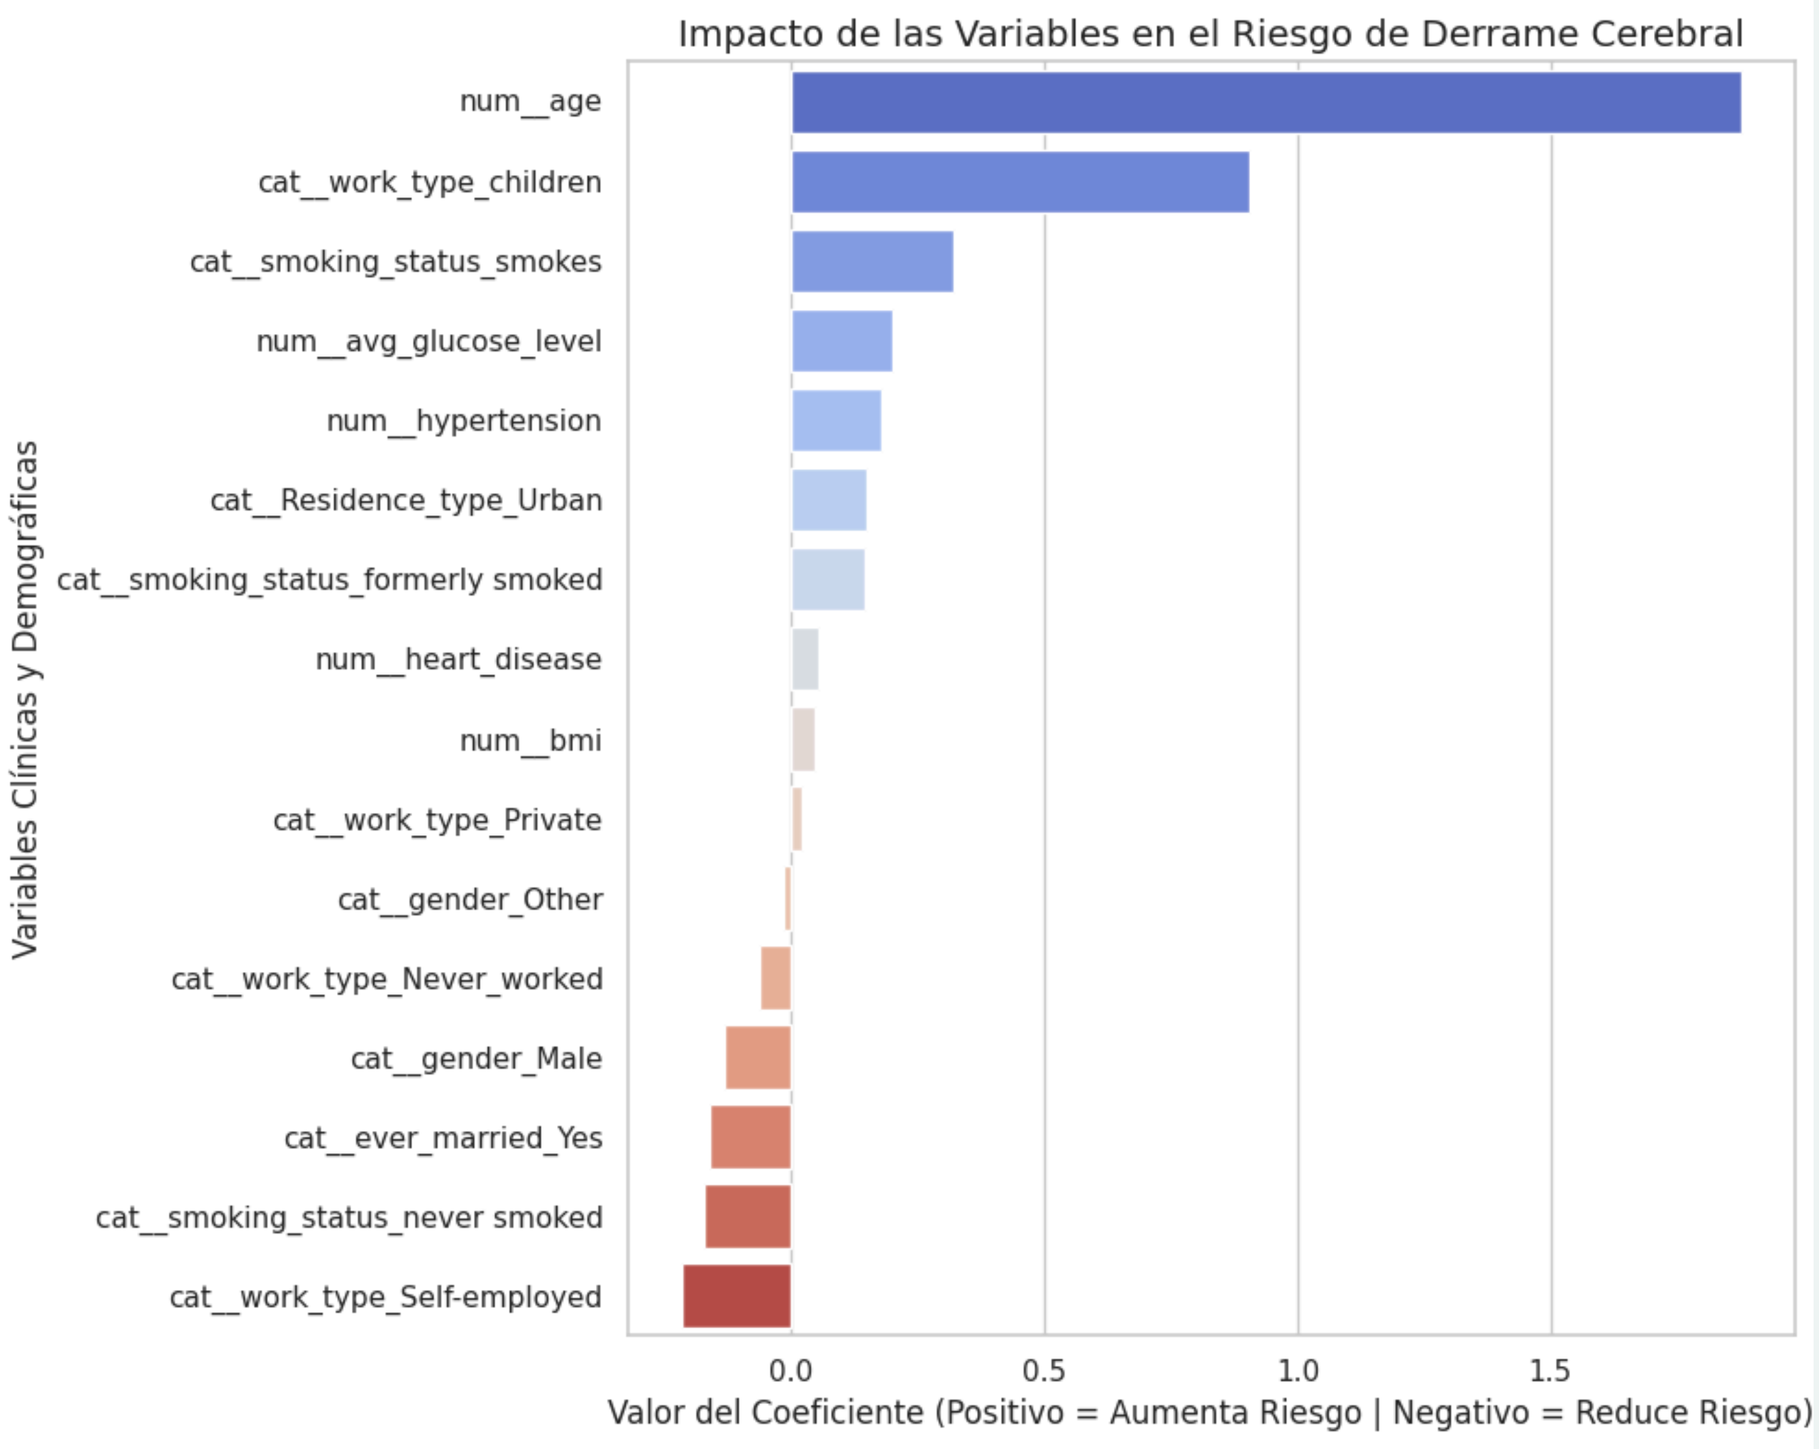
Impacto de las Variables en el Riesgo de Derrame Cerebral
num__age
cat__work_type_children
cat__smoking_status_smokes
num__avg_glucose_level
num__hypertension
cat__Residence_type_Urban
cat__smoking_status_formerly smoked
num__heart_disease
num__bmi
cat__work_type_Private
cat__gender_Other
cat__work_type_Never_worked
cat__gender_Male
cat__ever_married_Yes
cat__smoking_status_never smoked
cat__work_type_Self-employed
Variables Clínicas y Demográficas
0.0
0.5
1.0
1.5
Valor del Coeficiente (Positivo = Aumenta Riesgo | Negativo = Reduce Riesgo)

DECISIONES OPERATIVAS

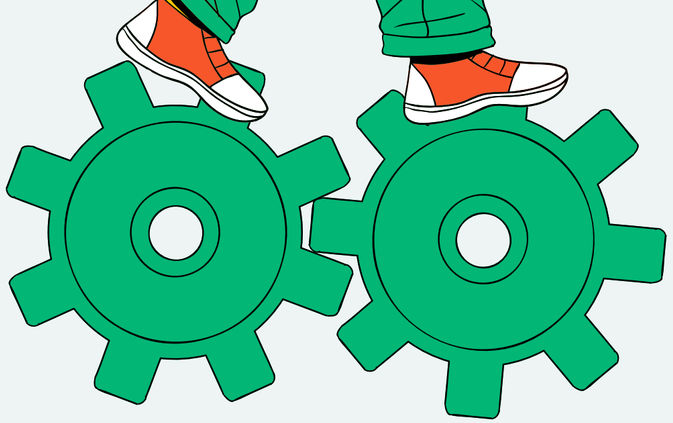

- EL COSTO DE UN FALSO NEGATIVO (IGNORAR UN DERRAME) ES CATASTRÓFICO FRENTE A UN FALSO POSITIVO (UN CHEQUEO EXTRA).
- ACCIÓN: REDUCIR EL UMBRAL DE DECISIÓN ALGORÍTMICA AL 35%.
- CONTACTAR PROACTIVAMENTE A CUALQUIER PACIENTE QUE SUPERE ESTE LÍMITE.

TRABAJO FUTURO Y LIMITACIONES

LA REGRESIÓN LINEAL ES INSUFICIENTE PARA VARIABLES MÉDICAS EXTREMAS.

COMO MEJORA FUTURA, PROPONEMOS IMPLEMENTAR ALGORITMOS DEL ECOSISTEMA BOOSTING (XGBOOST, LIGHTGBM O CATBOOST).

ESTOS MODELOS CAPTURAN RELACIONES NO LINEALES NATIVAMENTE Y SON MÁS ROBUSTOS FRENTE A VALORES ATÍPICOS.
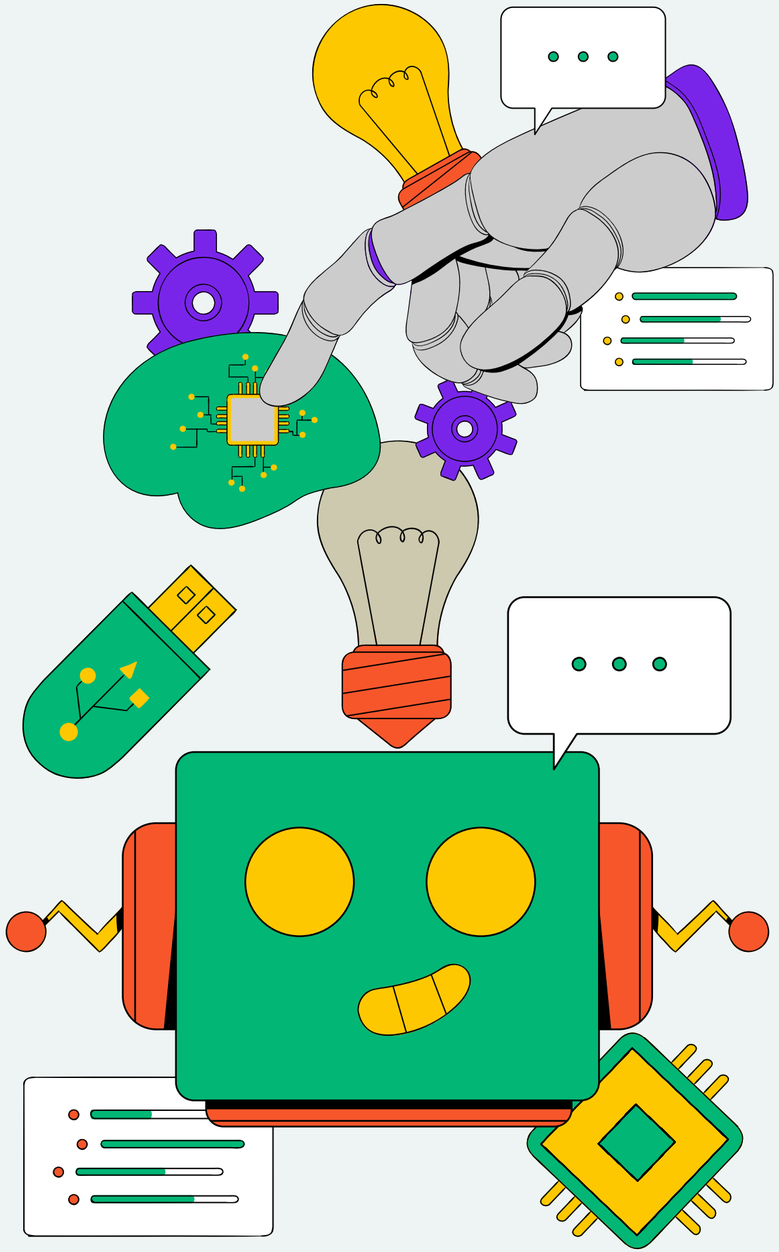
GRACIAS